Лабораторная работа №2 - Обработка и подготовка данных в Pandas

Цель

Сформировать навык загрузки, очистки, преобразования и первичного разведочного анализа табличных данных с использованием библиотеки Pandas.

Задачи работы

Научиться:

- загружать данные из различных источников (CSV, Excel, JSON) в структуры Pandas;
- проводить первичный обзор структуры и типов данных набора;
- выявлять и обрабатывать пропущенные значения и дубликаты;
- выполнять фильтрацию, сортировку и создание новых признаков;
- применять группировку и агрегацию (`groupby`) для получения сводных показателей;
- объединять несколько наборов данных (`merge`, `join`, `concat`);
- формировать итоговый отчёт разведочного анализа данных (EDA).

Методические указания к выполнению лабораторной работы

Каждый студент выбирает один набор данных из открытых источников (не должен повторяться с другими студентами из потока) и использует его на всех трёх занятиях лабораторной работы (сквозной датасет). Название и ссылку на датасет необходимо записать в файл таблицу в Moodle, чтобы исключить повторение:

- Kaggle Datasets — kaggle.com/datasets
- data.gov / data.europa.eu — открытые государственные данные
- Росстат (открытые данные) — rosstat.gov.ru

- Университетский репозиторий UCI ML Repository — archive.ics.uci.edu

Требование к датасету: не менее 500 строк, не менее 6 столбцов, наличие как числовых, так и категориальных признаков, обязетельно — наличие пропусков или дубликатов (можно создать намеренно).

Занятие 1. Загрузка данных и обзор структуры

Часть 1. Загрузка данных из разных источников

Задание 1.1. Загрузить выбранный датасет в DataFrame с помощью `pd.read_csv()`. Продемонстрировать загрузку данных ещё из двух форматов на примерах учебных мини-файлов, подготовленных преподавателем: `pd.read_excel()` и `pd.read_json()`.

Задание 1.2. Изучить и применить ключевые параметры `read_csv`: `sep`, `encoding`, `header`, `usecols`, `parse_dates`, `na_values`. Продемонстрировать на конкретном примере, зачем нужен каждый из них.

Часть 2. Обзор структуры данных

Задание 1.3. Получить общее описание датасета:

- `df.head()`, `df.tail()`, `df.sample(5)`;
- `df.shape`, `df.info()`, `df.dtypes`;
- `df.describe()` — для числовых и отдельно для категориальных столбцов (`include='object'`).

Задание 1.4. Для каждого столбца определить и зафиксировать в текстовом выводе:

- тип признака (количественный / категориальный / порядковый / дата);
- количество уникальных значений (`nunique()`);
- есть ли явные аномалии (нереалистичные min/max, подозрительные категории).

Задание 1.5. Изменить некорректно определённый тип хотя бы одного столбца (например, привести строковый столбец с датой к `datetime64` через `pd.to_datetime`).

Занятие 2. Очистка данных, фильтрация, группировка

Часть 1. Пропуски и дубликаты

Задание 2.1. Выявить пропущенные значения: `df.isnull().sum()`, визуально оценить долю пропусков по каждому столбцу (в процентах).

Задание 2.2. Обработать пропуски не менее чем тремя разными способами в зависимости от типа столбца:

- удаление строк/столбцов с критичной долей пропусков (`dropna`);
- заполнение константой или модой для категориальных признаков (`fillna`);
- заполнение средним/медианой для числовых признаков.

Обосновать в текстовом выводе выбор способа для каждого случая.

Задание 2.3. Найти и удалить дубликаты строк (`duplicated()`, `drop_duplicates()`), зафиксировать, сколько строк было удалено.

Часть 2. Фильтрация и новые признаки

Задание 2.4. Выполнить фильтрацию данных по нескольким условиям одновременно (с использованием `&`, `|`), отсортировать результат по одному числовому и одному категориальному столбцу (`sort_values`).

Задание 2.5. Создать не менее двух новых признаков на основе существующих столбцов — например: категоризация числового признака через `pd.cut`, вычисляемый признак как комбинация двух других столбцов, извлечение года/месяца из столбца с датой.

Часть 3. Группировка и агрегация

Задание 2.6. Выполнить группировку данных по категориальному признаку (`groupby`) и рассчитать для каждой группы не менее трёх агрегатов (`mean`, `count`, `sum`, `median` и т.д.) с помощью `.agg()`.

Задание 2.7. Построить сводную таблицу с помощью `pd.pivot_table()` по двум измерениям. Сформулировать вывод: какая группа/категория показывает наибольшее/наименьшее значение целевого показателя и предположить, почему.

Занятие 3. Объединение данных и итоговый EDA-отчёт

Часть 1. Объединение наборов данных

Задание 3.1. Разбить исходный датасет на две части по столбцу-ключу (искусственно, с помощью среза/фильтра) и объединить их обратно, продемонстрировав на практике разницу между:

- `pd.concat()` — объединение «по вертикали»/«по горизонтали»;
- `pd.merge()` с параметрами `how='inner'`, `'left'`, `'outer'` — и объяснить разницу в результирующем количестве строк для каждого типа.

Задание 3.2. Дополнить основной датасет вторым, тематически связанным набором данных (например, справочником категорий, курсом валют, географическим справочником) через merge по общему ключу.

Часть 2. Формирование итогового EDA-отчёта

Задание 3.3. Сформировать в конце notebook раздел «Итоговый отчёт разведочного анализа данных», включающий:

- краткое описание датасета (источник, объём, состав признаков — 3–5 предложений);
- сводку по качеству данных до и после очистки (сколько пропусков/дубликатов было устранено);
- три содержательных наблюдения (инсайта), полученных в ходе группировки и агрегации, с подтверждающими таблицами;
- описание созданных новых признаков и их назначение;
- общий вывод о пригодности датасета для дальнейшего анализа (2–3 предложения).

Контрольные вопросы

1. В чём разница между Series и DataFrame?
2. Какие есть способы обработки пропущенных значений и когда какой уместен?
3. Чем отличаются `merge`, `join` и `concat` друг от друга?
4. Что произойдёт с количеством строк при `how='inner'` против `how='outer'`, если ключи в двух таблицах не полностью совпадают?
5. Для чего нужен `groupby` и как он связан с идеей «split-apply-combine»?
6. В чём разница между `df.copy()` и обычным присваиванием DataFrame другой переменной?

Требования к защите

На защите необходимо наличие проекта и отчета. Отчет по лабораторной работе делается в электронном виде (структура – титульный лист, задание, выполнение со скриншотами, вывод), пользоваться им на защите нельзя. Отчет загружается в Moodle.

Проект оформляется в виде единого Jupyter Notebook (.ipynb):

- markdown-заголовки к каждому заданию;
- код, notebook сдаётся выполненным, без ошибок;
- итоговый раздел EDA-отчёта в конце файла.

Файл именуется по шаблону: №Group_Familia_IO_LR2.ipynb.

Комментарии должны отсутствовать как в коде, так и в отчёте. Тоже самое касается подсказок в коде. Наличие комментариев и подсказок будет означать, что работа не сдана. Ее можно сдать только на следующую пару!!!

Рекомендуемые источники

1. Официальная документация Pandas: https://pandas.pydata.org/docs/
2. McKinney W. Python for Data Analysis — главы по Pandas (свободно доступны материалы автора онлайн).
3. Kaggle Learn: курс «Pandas» — https://www.kaggle.com/learn/pandas

Таблица 1 – Технический стек

Инструмент	**Назначение**	**Ссылка**
Python 3.10+ / Anaconda или Google Colab	среда выполнения	anaconda.com / colab.research.google.com
Jupyter Notebook/Lab	интерактивная среда разработки	входит в Anaconda
Pandas	библиотека для работы с табличными данными	pandas.pydata.org
openpyxl	чтение/запись Excel-файлов (зависимость Pandas)	устанавливается автоматически