Лабораторная работа №3 - Визуализация данных

Цель

Сформировать навык выбора типа графика под аналитическую задачу и построения информативных статических и интерактивных визуализаций данных.

Задачи работы

Научиться:

- выбирать тип графика в зависимости от характера данных и задачи (распределение, сравнение, взаимосвязь, динамика);
- строить статические визуализации средствами Matplotlib и Seaborn;
- строить интерактивные визуализации средствами Plotly;
- распознавать и избегать типичные ошибки визуализации;
- сопровождать графики содержательными текстовыми выводами.

Методические указания к выполнению лабораторной работы

Используется тот же датасет, что был очищен и подготовлен в Лабораторной работе №2. Если очищенная версия не сохранена — необходимо перед началом работы повторно выполнить базовую очистку (обработка пропусков и дубликатов) на исходном наборе.

Занятие 1. Статическая визуализация: Matplotlib и Seaborn

Часть 1. Визуализация распределений

Задание 1.1. Для одного числового признака датасета построить:

- гистограмму распределения (`plt.hist` или `sns.histplot`) с обоснованным выбором количества интервалов (`bins`);
- график плотности распределения (`sns.kdeplot`);

- boxplot (`sns.boxplot`) с отметкой выбросов.

Сформулировать вывод о форме распределения (симметричное/скошенное, наличие выбросов).

Часть 2. Визуализация сравнений

Задание 1.2. Построить столбчатую диаграмму (`sns.barplot` или `plt.bar`), сравнивающую средние значения числового признака по категориям (используя результат группировки из ЛР2).

Задание 1.3. Построить сгруппированный (`grouped`) barplot, сравнивающий значения показателя одновременно по двум категориальным признакам.

Часть 3. Визуализация взаимосвязей

Задание 1.4. Построить диаграмму рассеяния (`sns.scatterplot`) между двумя числовыми признаками, добавив цветовое кодирование (`hue`) по категориальному признаку.

Задание 1.5. Построить тепловую карту корреляций (`sns.heatmap` + `df.corr()`) для всех числовых признаков датасета. Определить и назвать в текстовом выводе пару признаков с наиболее сильной корреляцией.

Занятие 2. Интерактивная визуализация и типичные ошибки

Часть 1. Типичные ошибки визуализации

Задание 2.1. Изучить и кратко законспектировать (в markdown-ячейке, своими словами, с иллюстрацией на данных своего датасета там, где возможно) три типичные ошибки визуализации:

- искажение масштаба оси Y (обрезанная ось, создающая ложное впечатление о разнице значений);
- неверный выбор типа графика (например, круговая диаграмма для данных с большим числом категорий);
- перегруженность графика избыточными элементами (3D-эффекты, лишние цвета, отсутствие подписей осей).

Для одного из пунктов построить «плохой» и «исправленный» вариант графика на одних и тех же данных.

Часть 2. Динамика и интерактивная визуализация в Plotly

Задание 2.2. Если в датасете присутствует временной признак — построить линейный график динамики показателя во времени средствами `plotly.express` (`px.line`), с интерактивными подсказками (hover) при наведении. Если временного признака нет — построить интерактивную диаграмму рассеяния (`px.scatter`) с hover-подсказками, показывающими значения нескольких признаков одновременно.

Задание 2.3. Построить интерактивную столбчатую диаграмму (`px.bar`) сравнения категорий с возможностью сортировки и всплывающими подсказками.

Часть 3. Итоговая визуальная сводка

Задание 2.4. Собрать в конце notebook итоговый раздел «Визуальная сводка по датасету», состоящий из 5–6 графиков (комбинация статических и интерактивных, построенных ранее либо новых), которые в совокупности наиболее полно раскрывают структуру и особенности выбранного датасета. Для каждого графика:

- указать, к какому типу задачи он относится (распределение / сравнение / взаимосвязь / динамика);
- дать содержательный вывод.

В конце раздела сформулировать общее заключение (3–4 предложения): какие закономерности в данных были визуально выявлены.

Контрольные вопросы

1. В каком случае предпочтительнее использовать boxplot, а в каком — гистограмму?
2. Почему круговые диаграммы считаются плохим выбором при большом числе категорий?

3. Чем отличается архитектура Seaborn от Matplotlib (в чём Seaborn — надстройка)?
4. Какие преимущества даёт интерактивная визуализация (Plotly) по сравнению со статической при исследовательском анализе данных?
5. Что показывает тепловая карта корреляций и как трактовать значение, близкое к 0?
6. Приведите пример, когда визуализация может ввести в заблуждение, даже если данные на графике корректны.

Требования к защите

На защите необходимо наличие проекта и отчета. Отчет по лабораторной работе делается в электронном виде (структура – титульный лист, задание, выполнение со скриншотами, вывод), пользоваться им на защите нельзя. Отчет загружается в Moodle.

Проект оформляется в виде единого Jupyter Notebook (.ipynb):

- markdown-заголовки к каждому заданию;
- код, notebook сдаётся выполненным, графики должны отображаться непосредственно в выводе ячеек;
- под каждым графиком - какой инсайт из него следует.

Файл именуется по шаблону: №Group_Familia_IO_LR3.ipynb.

Комментарии должны отсутствовать как в коде, так и в отчёте. Тоже самое касается подсказок в коде. Наличие комментариев и подсказок будет означать, что работа не сдана. Ее можно сдать только на следующую пару!!!

Рекомендуемые источники

1. Официальная документация Matplotlib: https://matplotlib.org/stable/
2. Официальная документация Seaborn: https://seaborn.pydata.org/
3. Официальная документация Plotly (Python): https://plotly.com/python/

4. Cairo A. The Truthful Art — о принципах достоверной визуализации данных (главы доступны в открытых обзорах и лекционных материалах автора).

Таблица 1 – Технический стек

Инструмент	**Назначение**	**Ссылка**
Python 3.10+ / Anaconda или Google Colab	среда выполнения	anaconda.com / colab.research.google.com
Matplotlib	базовая библиотека статической визуализации	matplotlib.org
Seaborn	статистическая визуализация поверх Matplotlib	seaborn.pydata.org
Plotly	интерактивная визуализация	plotly.com/python