Лабораторная работа №4 - SQL для аналитических задач

Цель

Закрепить и углубить практические навыки извлечения, агрегации и аналитической обработки данных средствами SQL, включая построение простой аналитической витрины данных.

Задачи работы

Научиться:

- разворачивать и подключаться к реляционной СУБД, создавать схему базы данных и загружать в неё данные;
- писать запросы с использованием агрегатных функций, `GROUP BY`, `HAVING`;
- использовать подзапросы и обобщённые табличные выражения (CTE);
- применять оконные функции для аналитических расчётов;
- проектировать простую схему аналитической витрины данных («звезда»);
- составлять отчётные аналитические запросы под конкретную бизнес-задачу.

Методические указания к выполнению лабораторной работы

Используется тот же датасет, что был подготовлен в Лабораторных работах №2–3. Датасет загружается в СУБД как одна или несколько таблиц.

Занятие 1. Развёртывание СУБД, создание схемы, загрузка данных

Часть 1. Установка и подключение

Задание 1.1. Установить PostgreSQL (или любую доступную) и подключиться к базе данных через DBeaver Community Edition. Создать новую базу данных `data_tools_lab`.

Часть 2. Проектирование схемы

Задание 1.2. Спроектировать схему из не менее трёх связанных таблиц на основе выбранного датасета (например: `orders`, `customers`, `products`). Определить для каждой таблицы первичный ключ, для связанных таблиц — внешние ключи. Изобразить ER-диаграмму (от руки, в любом графическом редакторе или средствами DBeaver) и приложить к отчёту.

Задание 1.3. Написать DDL-запросы `CREATE TABLE` для всех таблиц схемы с указанием типов данных, `PRIMARY KEY` и `FOREIGN KEY`.

Часть 3. Загрузка данных

Задание 1.4. Загрузить данные в созданные таблицы: через импорт CSV средствами DBeaver либо через `INSERT INTO` для небольшого набора строк. Проверить корректность загрузки простым запросом `SELECT * FROM ... LIMIT 10`.

Задание 1.5. Выполнить проверочные запросы: подсчитать количество строк в каждой таблице (`COUNT(*)`), убедиться в отсутствии «повисших» внешних ключей (строк со ссылкой на несуществующую запись в связанной таблице).

Занятие 2. Агрегатные функции, GROUP BY/HAVING, подзапросы, CTE

Часть 1. Агрегатные функции и группировка

Задание 2.1. Написать запросы с использованием агрегатных функций `COUNT`, `SUM`, `AVG`, `MIN`, `MAX` без группировки — получить общие показатели по всей таблице.

Задание 2.2. Написать не менее трёх запросов с `GROUP BY` по разным признакам (например: количество заказов по каждому клиенту; средняя сумма заказа по категориям товаров), отсортировать результат по убыванию агрегата (`ORDER BY ... DESC`).

Задание 2.3. Дополнить один из запросов условием `HAVING`, отбирающим только группы, удовлетворяющие агрегатному условию (например, клиентов с более чем 3 заказами).

Часть 2. Подзапросы

Задание 2.4. Написать запрос с подзапросом в секции `WHERE` (например: найти товары, цена которых выше средней цены по всем товарам).

Задание 2.5. Написать запрос с коррелированным подзапросом (например: для каждого клиента найти его самый дорогой заказ).

Часть 3. Обобщённые табличные выражения — CTE

Задание 2.6. Переписать один из предыдущих запросов с подзапросом с использованием `WITH ... AS (CTE)`, сравнить читаемость обоих вариантов в текстовом выводе.

Задание 2.7. Написать запрос с несколькими последовательными CTE (второй CTE использует результат первого) для решения многошаговой аналитической задачи (например: сначала посчитать сумму заказов по клиентам, затем отобрать топ-10 клиентов по этой сумме).

Занятие 3. Оконные функции и аналитическая витрина данных

Часть 1. Оконные функции

Задание 3.1. Написать запрос с функцией `ROW_NUMBER() OVER (PARTITION BY ... ORDER BY ...)` — например, пронумеровать заказы каждого клиента в хронологическом порядке.

Задание 3.2. Написать запрос с `RANK()` или `DENSE_RANK()` для ранжирования (например, ранжирование товаров по объёму продаж внутри каждой категории).

Задание 3.3. Написать запрос с агрегатной оконной функцией без группировки строк (например, `SUM(...) OVER (PARTITION BY ...)` — сумма заказов клиента, отображаемая в каждой строке его заказов) и с функцией `LAG()/LEAD()` (например, сравнение суммы текущего заказа с предыдущим заказом того же клиента).

Часть 2. Проектирование аналитической витрины данных

Задание 3.4. На основе имеющейся схемы спроектировать упрощённую схему «звезда»: выделить таблицу фактов (например, `fact_orders` — с числовыми показателями: суммой, количеством) и не менее двух таблиц измерений (`dim_customers`, `dim_products` или `dim_date`). Изобразить схему и кратко объяснить, чем она отличается от исходной нормализованной схемы из первой части ЛР1.

Задание 3.5. Написать SQL-запрос (`CREATE TABLE ... AS SELECT` или `CREATE VIEW`), формирующий таблицу/представление фактов на основе исходных данных.

Часть 3. Итоговые отчётные запросы

Задание 3.6. Составить и выполнить три отчётных аналитических запроса, отвечающих на конкретные бизнес-вопросы по выбранному датасету (например: «Топ-5 клиентов по сумме покупок за всё время», «Динамика количества заказов по месяцам», «Доля каждой категории товаров в общей выручке»). Каждый запрос должен использовать хотя бы одну из изученных конструкций (агрегация, подзапрос/CTE, оконная функция). Сформулировать содержательный вывод по каждому запросу.

Контрольные вопросы

1. В чём разница между `WHERE` и `HAVING`?
2. Чем оконная функция принципиально отличается от `GROUP BY` с точки зрения количества строк в результате?
3. Что такое CTE и в каких случаях он предпочтительнее подзапроса?
4. Объясните разницу между `RANK()` и `DENSE_RANK()` на конкретном примере с повторяющимися значениями.
5. Что такое схема «звезда» и зачем она нужна в аналитических системах вместо нормализованной схемы?
6. Чем аналитическая (OLAP) СУБД принципиально отличается от транзакционной (OLTP)?

Требования к защите

На защите необходимо наличие проекта и отчета. Отчет по лабораторной работе делается в электронном виде (структура – титульный лист, задание, выполнение со скриншотами, выводы), пользоваться им на защите нельзя. Отчет загружается в Moodle.

Файл именуется по шаблону: №Group_Familia_IO_LR4.

Комментарии должны отсутствовать как в коде, так и в отчёте. Тоже самое касается подсказок в коде. Наличие комментариев и подсказок будет означать, что работа не сдана. Ее можно сдать только на следующую пару!!!

Рекомендуемые источники

1. Официальная документация PostgreSQL: https://www.postgresql.org/docs/
2. Официальная документация SQLite: https://www.sqlite.org/docs.html
3. Документация DBeaver: https://dbeaver.io/docs/
4. Молинаро А. SQL. Сборник рецептов — главы по агрегации, подзапросам и оконным функциям.

Таблица 1 – Технический стек

Инструмент	**Назначение**	**Ссылка**
PostgreSQL	реляционная СУБД (open source, бесплатна)	postgresql.org
SQLite (альтернатива)	встраиваемая СУБД, не требует установки сервера	sqlite.org
DBeaver Community Edition	графический клиент для работы с БД	dbeaver.io